
Brownian Motion and Stochastic Calculus

最終更新: 2022 年 10 月 19 日

注意: 記述の正確性は保証しません. ややこしいことになりたくないので, 本文の引用は最小限にしています. ? マークは不明/自信なし/要復習を意味しています.

確率論の復習 [1]

確率空間を作る

- 抽象空間 Ω^{*1} と σ -field^{*2} $\mathcal{F} \subset \mathcal{P}(\Omega)$ の組 (Ω, \mathcal{F}) を **可測空間** という.
- 可測空間 (Ω, \mathcal{F}) 上の測度^{*3}で $P(\Omega) = 1$ をみたすものを **確率測度** という.
- (Ω, \mathcal{F}, P) を **確率空間** という. \mathcal{F} は確率を測ることができる事象の集まり. 情報量とみなせる.

測度 0 集合に関する用語

- 事象 $A \in \mathcal{F}$ が $P(A) = 1$ をみたすとき, A が **ほとんど確実に** 起こるといい, A a.s. とかく.
- (Ω, \mathcal{F}, P) が **完備** とは, 零集合の部分集合がすべて可測のときにいう.
- (Ω, \mathcal{F}, P) からその完備な拡張である **完備化** $(\Omega, \tilde{\mathcal{F}}, \tilde{P})$ を構成できる.

確率変数

- (Ω, \mathcal{F}, P) : 確率空間, (S, \mathcal{S}) : 可測空間. $X = X(\omega)$ が **S -値確率変数** であるとは, $X : (\Omega, \mathcal{F}) \rightarrow (S, \mathcal{S})$ が可測写像である^{*4}ときという.
- 写像 X が確率変数であることと同値な条件としては $\forall a \in \mathbb{R}, \{X \leq a\} \in \mathcal{F}$ などがある^{*5}.
- X が確率変数になるような最小限の \mathcal{F} が作れる: $\mathcal{F} = \mathcal{F}_X := \{X^{-1}(A); A \in \mathcal{S}\}$ とすればよい. \mathcal{F}_X を **確率変数 X が生成する σ -field** といい, $\sigma(X)$ とかく.

分布

- 確率変数 X の **分布, distribution** とは $P_X(A) = P(X^{-1}(A))$ によって定義される (S, \mathcal{S}) 上の確率測度 P_X のことをいう.^{*6}
- μ を $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ 上の確率測度とすると, $F(x) := F_\mu(x) = \mu((-\infty, x]), x \in \mathbb{R}$ を μ の **分布関数** という.
- X を確率変数とすると, その分布 P_X の分布関数 F_X を X の**分布関数** という. つまり $F_X(x) = P(X \leq x), x \in \mathbb{R}$ である.

^{*1} ただの集合. なんの構造ももたない.

^{*2} 3 条件: (1) $\Omega \in \mathcal{F}$. (2) 補集合で閉じている. (3) 加算和で閉じている.

^{*3} σ -additivity: A_n たちが互いに交わらないとき $P(\cup_n A_n) = \sum_n P(A_n)$ をみたす $P : \mathcal{F} \rightarrow [0, \infty]$ を**測度**というのだった.

^{*4} \mathcal{S} に属する集合の逆像が \mathcal{F} に属する.

^{*5} $\{X \leq a\}$ は基本的な事象であり, 当然その確率が定義されることが望まれる. 確率が定義できるためには, それは \mathcal{F} に属さねばならない. 確率変数とは, そのような望ましい性質をもつ関数である.

^{*6} 確率変数の分布に着目するという立場からいえば, 確率空間のとりかたには任意性がある. Ω 自身がそれほど重要で積極的な意味をもつわけではない: 確率空間 Ω を区間 $(0, 1)$ にとりかえて, 同じ分布をもつように確率変数を再構成することが可能である.

期待値

- **期待値** $E[X] = \int_{\Omega} X(\omega)P(d\omega)^{*7}$. 事象 A 上に限るとき $E[X, A] := \int_A X(\omega)P(d\omega) = E[X \cdot 1_A]$.

不等式

- **Chebyshev** $P(|X| > \epsilon) \leq \frac{1}{\epsilon^p} E[|X|^p]$.
- **Jensen** $\psi: \mathbb{R} \rightarrow \mathbb{R}$: 下に凸. $\psi(E[X]) \leq E[\psi(X)]$.
- **Hölder** $1 < p, q < \infty$ が $1/p + 1/q = 1$ をみたすとき, $|E[XY]| \leq E[|X|^p]^{\frac{1}{p}} E[|Y|^q]^{\frac{1}{q}}$.
- **Schwarz Hölder** で $p = q = 2$ とおく.

期待値と極限操作の交換

- **Lebesgue's convergence theorem** $X_n \rightarrow X(a.s.)$ かつ非負確率変数 Y で可積分なものが存在し $\forall n, |X_n| \leq Y$ をみたすならば $\lim_n E[X_n] = E[X]$.
- **monotone convergence theorem** $0 \leq X_1 \leq X_2 \leq \dots$ かつ $X_n \rightarrow X(a.s.)$ ならば $\lim_n E[X_n] = E[X]$.
- **Fatou's lemma** $X_n \geq 0$ ならば $E[\liminf_n X_n] \leq \liminf_n E[X_n]$.

いろいろな収束

1. **a.s. convergence** $X_n(\omega) \rightarrow X(\omega)$ a.s. つまり $P(\lim_n X_n = X) = 1$.
2. **convergence in probability** 任意の $\epsilon > 0$ に対して $\lim_n P(|X_n - X| > \epsilon) = 0$.
3. **convergence in the mean of order p** $p \geq 1$ に対し $\lim_n E[|X_n - X|^p] = 0$.
4. **convergence in law/distribution** 任意の $f \in C_b(\mathbb{R})$ に対して $\lim_n E[f(X_n)] = E[f(X)]^{*8}$.

1 \implies 2, 3 \implies 2, 2 \implies 4. **一様可積分** というを導入すると逆向きの矢印が成り立つようになったりする.

独立性の定義

- 事象の独立性: 事象の集まり $\{A_k\}_{1 \leq k \leq n}$ が **独立** $\stackrel{\text{def}}{\iff}$ 任意の $1 \leq l \leq n$ と任意の $1 \leq k_1 < k_2 < \dots < k_l \leq n$ に対して

$$P\left(\bigcap_{i=1}^l A_{k_i}\right) = \prod_{i=1}^l P(A_{k_i}).$$

- σ -field の独立性: \mathcal{F} の部分 σ -field $\mathcal{F}_1, \mathcal{F}_2, \dots, \mathcal{F}_n$ が **独立** $\stackrel{\text{def}}{\iff}$ 任意の $C_k \in \mathcal{F}_k$ ($1 \leq k \leq n$) に対して

$$P(C_1 \cap C_2 \cap \dots \cap C_n) = \prod_{k=1}^n P(C_k).$$

- 確率変数列の独立性: S_k -値確率変数列 $(X_k)_{1 \leq k \leq n}$ が **独立** $\stackrel{\text{def}}{\iff}$ 任意の $A_k \in \mathcal{S}_k$ ($1 \leq k \leq n$) に対して

$$P(X_k \in A_k, k = 1, 2, \dots, n) = \prod_{k=1}^n P(X_k \in A_k).$$

^{*7} 可積分のとき.

^{*8} $(X_n), X$ の分布のみによって定まる概念だから, これらは必ずしも同一の確率空間で定義されている必要はない.

独立性に関する性質

- 確率変数列の独立性は、可測関数との合成によって保たれる。
- 可積分な独立な確率変数列 (X_k) に対し、 $E[X_1 X_2 \cdots X_n] = E[X_1] E[X_2] \cdots E[X_n]$.
- 組ごとに独立な確率変数列 (X_k) に対し、 $\text{Var}(X_k) < \infty, 1 \leq k \leq n$ ならば、 $\text{Var}(\sum_{k=1}^n X_k) = \sum_{k=1}^n \text{Var}(X_k)$.

独立確率変数列の存在

- 直積 σ -field と 直積測度を入れた確率空間に、独立確率変数列を構成できる。まず有限個でやってから、柱状集合から Kolmogorov の σ -field を作って無限確率変数列に拡張する。

条件つき期待値

\mathcal{G} を \mathcal{F} の部分 σ -field とする。 X は確率変数。 条件

1. $B \in \mathcal{G} \implies E[X, B] = E[Y, B]$
2. Y は \mathcal{G} -可測な確率変数

をみたす確率変数 $Y(\omega)$ を $E[X|\mathcal{G}](\omega)$ とかいて、 \mathcal{G} の下での X の **条件つき期待値** という。

条件つき期待値の性質

1. $a, b \in \mathbb{R}$ に対し、 $E[aX + bY|\mathcal{G}] = aE[X|\mathcal{G}] + bE[Y|\mathcal{G}]$, $a.s.$
2. $X \geq 0$, $a.s. \implies E[X|\mathcal{G}] \geq 0$, $a.s.$
3. X が \mathcal{G} -可測で XY が可積分ならば $E[XY|\mathcal{G}] = XE[Y|\mathcal{G}]$, $a.s.$
4. \mathcal{H}, \mathcal{G} を \mathcal{F} の部分 σ -field で $\mathcal{H} \subset \mathcal{G}$ とすれば $E[E[X|\mathcal{G}]|\mathcal{H}] = E[X|\mathcal{H}]$, $a.s.$
5. X と \mathcal{G} が独立ならば $E[X|\mathcal{G}] = E[X]$, $a.s.$ したがって f を \mathbb{R} 上の Borel 可測関数として $f(X)$ が可積分ならば $E[f(X)|\mathcal{G}] = E[f(X)]$.

大数の法則

- (X_k) の 標本平均 Y_n

$$Y_n := \frac{1}{n} \sum_{k=1}^n X_k, \quad \bar{m}_n = \frac{1}{n} \sum_{k=1}^n m_k \quad (1)$$

- 規格化された標本平均 $\tilde{Y}_n := Y_n - \bar{m}_n$.
- (大数の弱法則) ある条件^{*9}のもとで、 $\tilde{Y}_n \rightarrow 0$, 確率収束
- (大数の強法則 1,2) ある条件^{*10*11}のもとで、 $\tilde{Y}_n \rightarrow 0$, 概収束。

大数の強法則の証明に用いる道具

- (Borel-Cantelli の補題)

^{*9} 1. (X_n) が組ごとに独立. 2. $\sup_n \text{Var}(X_n) < \infty$.

^{*10} 1. (X_n) が独立. 2. $\sum_{n=1}^{\infty} \frac{1}{n^2} \text{Var}(X_n) < \infty$. (Kolmogorov の第 1 定理)

^{*11} 1. (X_n) は i.i.d. 2. $m = E[X_n] < \infty$. (Kolmogorov の第 2 定理)

- (Kolmogorov の不等式)

中心極限定理

大数の法則は標本平均 Y_n の収束極限 $E[X]$ についてのべたものである。しかし、このような結果を現実に応用しようとする場合、「 n を実際にどの程度大きくとれば Y_n が $E[X]$ に十分近いといえるのか」が重要。中心極限定理 (CLT) は大数の法則の誤差項 $Y_n - E[X]$ の挙動を調べるものであり、雑にいうと、この項は $n \rightarrow \infty$ のとき $O(1/\sqrt{n})$ で減衰し、

$$Y_n = \frac{1}{n} \sum_{k=1}^n X_k = E[X] + \frac{1}{\sqrt{n}} Z + \dots$$

となるような Z が求まることを主張している。具体的には $Z \sim \mathcal{N}(0, \sigma^2)$ である。

$$Z_n = \sqrt{n} \left(\frac{1}{n} \sum_{k=1}^n X_k - E[X] \right), \quad Z_n \rightarrow Z.$$

しかし、収束の意味は（概収束や確率収束よりも弱い）法則収束（弱収束、分布収束）である。つまり、 $P(a \leq Z_n \leq b)$ が $n \rightarrow \infty$ のときに Z の対応する確率 $P(a \leq Z \leq b)$ に収束することが期待できる。

CLT の証明に向かって

- (弱収束と同値な条件)
- (Prokhorov の定理) (μ_α) は相対コンパクト $\iff (\mu_\alpha)$ は緊密 (tight).

証明の概略

1. Helly の選出定理を用いる。

特性関数

- 確率測度 μ の **特性関数** $\varphi(\xi) := \varphi_\mu(\xi) = \int_{\mathbb{R}} e^{i\xi x} \mu(dx)$, $\xi \in \mathbb{R}$.
- 確率変数 X の **特性関数** とは、 X の分布 P_X の特性関数のこと。つまり $\varphi(\xi) := \varphi_X(\xi) = E[e^{i\xi X}]$.
- (一意性定理) $\forall \xi \in \mathbb{R}, \varphi_\mu(\xi) = \varphi_{\tilde{\mu}}(\xi) \implies \mu = \tilde{\mu}$.
- 特性関数の各点収束は分布の弱収束と同値である。
- (Bochner の定理) 特性関数の特徴づけ: $\varphi(\xi)$ が
 1. $\xi = 0$ で連続
 2. $\varphi(0) = 1$
 3. 正定値
 をみたすなら φ はある $\mu \in \mathcal{P}(\mathbb{R})$ の特性関数。

CLT の証明

- (中心極限定理, CLT) (X_n) は i.i.d. 確率変数列で、 $E[X_n] = m, \text{Var}(X_n) = v$. このとき $Z_n = \sqrt{n}(\frac{1}{n} \sum_{k=1}^n X_k - m)$ は $Z_n \rightarrow Z$, 法則収束. ($Z \sim \mathcal{N}(0, v)$)

離散時間 Martingale

- \mathcal{F} の部分 σ -field の増加列 (\mathcal{F}_n) を**情報系 (filtration)** という。

- (X_n) が filtration (\mathcal{F}_n) に関して **martingale** $\stackrel{\text{def}}{\iff}$
 1. (\mathcal{F}_n) -adapted: 各 n に対し X_n は \mathcal{F}_n -可測.
 2. 各 X_n は可積分.
 3. $E[X_{n+1}|\mathcal{F}_n] = X_n, a.s.$ \geq なら **submartingale**, \leq なら **supermartingale**.
- $\mathcal{F}_n := \sigma(X_1, X_2, \dots, X_n)$ から定まる (\mathcal{F}_n) を (X_n) の **自然な filtration** という.
- 下に凸な関数 ψ による変換 $X_n \mapsto \psi(X_n)$ で martingale \rightarrow submartingale, submartingale \rightarrow submartingale.

Doob 分解

- submartingale は martingale と増加過程の和に分解できる.

Markov time, stopping time

- ランダムな時刻 τ が時刻 n あるいはそれ以前におこるかどうか時刻 n までの情報 (\mathcal{F}_n) から判断可能なものを (\mathcal{F}_n) -**Markov time** という.
 - A への **到達時刻** τ_A は Markov time
 - A からの **最終脱出時刻** σ_A は Markov time ではない.
- (\mathcal{F}_n) -Markov time τ に対し, τ 時以降は区別不能な σ -field \mathcal{F}_τ を τ 時までの情報量 という.

optional sampling theorem

- ある種のランダムな時間変更について martingale 性が保存される, つまり
- (X_n) : (\mathcal{F}_n) -submartingale, (τ_k) : 有界な (\mathcal{F}_n) -Markov time の増加列のとき, $(Y_k) := (X_{\tau_k})$ は (\mathcal{F}_{τ_k}) -submartingale.

Doob の不等式

- ある時間区間における martingale の最大値は最後の時刻における情報のみによって評価できる:

$$P\left(\max_{1 \leq k \leq n} X_k \geq a\right) \leq \frac{1}{a} E[X_n^+].$$

submartingale の収束定理

- 単調増加実数列 (a_n) が上に有界なら $\lim_{n \rightarrow \infty} a_n$ が存在する. この事実の確率バージョン.
- **(submartingale の収束定理)** submartingale (X_n) が有界性 $\sup_n E[X_n^+] < \infty$ をみたすとき, ある可積分な確率変数 X があって $X_n \rightarrow X, a.s.$ となる.

証明の概略

1. 上向き横断回数が無限回にならないことを示す.

p 次変動

- $[M]_n := \sum_{k=1}^n (M_k - M_{k-1})^2$ を (M_n) の **2 次変動** という.
- $p \geq 1$ に対し $\sum_{k=1}^n |M_k - M_{k-1}|^p$ を (M_n) の **p 次変動** という. $p = 1$ のとき **全変動** という.

連続時間 martingale の導入にともなう定義

- filtration (\mathcal{F}_t) , $t \in \mathbb{R}_{\geq 0}$ が **右連続** $\stackrel{\text{def}}{\iff}$ 任意の $t \geq 0$ に対して $\mathcal{F}_t = \mathcal{F}_{t+}$ がなりたつ. ($\mathcal{F}_{t+} := \bigcap_{\epsilon > 0} \mathcal{F}_{t+\epsilon}$)
- $(X_t)_{t \geq 0}$ が **右連続 (càdlàg)** $\stackrel{\text{def}}{\iff}$ 任意の $\omega \in \Omega$ に対し $X_t(\omega)$ が t について右連続かつ左極限をもつ.

1 Martingales, Stopping Times, and Filtrations

■2,10 (def.1.3 \implies def.1.1 \implies def.1.2 がなりたつこと)

- 1.3 \implies 1.1: 任意の $s \in [0, \infty)$ に対し明らかに $P[X_t = Y_t; \forall t \in [0, \infty)] \leq P[X_s = Y_s]$ がなりたつから, $P[X_t = Y_t; \forall t \in [0, \infty)] = 1 \implies \forall t \in [0, \infty), P[X_t = Y_t] = 1$, つまり 1.3 \implies 1.1.
- 1.1 \implies 1.2: 不等式 $|P[(X_{t_1}, \dots, X_{t_n}) \in A] - P[(Y_{t_1}, \dots, Y_{t_n}) \in A]| \leq 2P[(X_{t_1}, \dots, X_{t_n}) \neq (Y_{t_1}, \dots, Y_{t_n})]$ を示す. 1.1 を仮定して不等式を用いれば, $|P[(X_{t_1}, \dots, X_{t_n}) \in A] - P[(Y_{t_1}, \dots, Y_{t_n}) \in A]| \leq 2P[(X_{t_1}, \dots, X_{t_n}) \neq (Y_{t_1}, \dots, Y_{t_n})] \leq \sum_{i=1}^n P(X_{t_i} \neq Y_{t_i}) = 0$ から 1.2 を得る. では不等式を示す. $\mathbf{X} = (X_{t_1}, \dots, X_{t_n})$, $\mathbf{Y} = (Y_{t_1}, \dots, Y_{t_n})$ とおく.

$$\begin{aligned} |P[\mathbf{X} \in A] - P[\mathbf{Y} \in A]| &= |P[(\mathbf{X} \in A) \cap (\mathbf{X} = \mathbf{Y})] + P[(\mathbf{X} \in A) \cap (\mathbf{X} \neq \mathbf{Y})] \\ &\quad - P[(\mathbf{Y} \in A) \cap (\mathbf{X} = \mathbf{Y})] - P[(\mathbf{Y} \in A) \cap (\mathbf{X} \neq \mathbf{Y})]| \\ &= |P[(\mathbf{X} \in A) \cap (\mathbf{X} \neq \mathbf{Y})] - P[(\mathbf{Y} \in A) \cap (\mathbf{X} \neq \mathbf{Y})]| \\ &\leq P[(\mathbf{X} \in A) \cap (\mathbf{X} \neq \mathbf{Y})] + P[(\mathbf{Y} \in A) \cap (\mathbf{X} \neq \mathbf{Y})] \\ &\leq 2P[\mathbf{X} \neq \mathbf{Y}] \end{aligned}$$

より示された. 他の導出法については [2] を参照.

参考文献

[1] 確率論, 舟木直久 (朝倉書店, 2004)

[2] [https://math.stackexchange.com/questions/1613202/if-one-stochastic-process-is-a-modification-of-an](https://math.stackexchange.com/questions/1613202/if-one-stochastic-process-is-a-modification-of-another)